

Dokumentácia k zadaniu 4

Spracovanie a segmentácia bodového oblaku


Tento projekt sa zameriava na spracovanie a segmentáciu 3D mračna bodov. Jeho cieľom je identifikovať a oddeliť objekty záujmu od pozadia a šumu, pričom pozadie tvoria prevažne rovinné plochy (napríklad podlaha a steny). Na vyčistené mračno sa následne aplikujú dve metódy klastrovania – **DBSCAN** a **K-Means**. Tie rozdelia body do zmysluplných skupín (klastrov), reprezentujúcich jednotlivé objekty.

Projekt využíva knižnicu Open3D v spojení s algoritmi strojového učenia z knižnice Scikit-learn. Tento prístup umožňuje spoľahlivú segmentáciu v prostredí s neštruktúrovanými dátami, kde nie je vopred známy počet objektov ani ich presná poloha.

Výstupom je vizualizácia klasifikovaných bodov, ktoré sú farebne odlíšené podľa príslušnosti ku klastru. Skript tiež umožňuje filtrovať príliš malé alebo nepodstatné skupiny bodov (pri DBSCAN).



Obrázok 1: Nasnímané mračno bodov



Obrázok 2: Stiahnuté mračno bodov

Odstránenie rovín pomocou RANSAC (Random Sample Consensus)

Na detekciu rovín v mračne bodov sa používa algoritmus RANSAC.

Postup fungovania algoritmu:

1. Náhodný výber minimálneho počtu bodov potrebných na určenie roviny
2. Výpočet rovinného modelu
3. Identifikácia všetkých bodov ležiacich v okolí tejto roviny (podľa nastavenej vzdialenosti)
4. Opakovanie procesu pre určený počet iterácií a výber modelu s najväčším počtom inlierov (bodov patriacich k rovine)
5. Odstránenie bodov patriacich k nájdenej rovine a zachovanie zvyšných bodov

RANSAC sa v projekte aplikuje iteratívne – každá iterácia odstráni najväčšiu detekovanú rovinu. Proces sa opakuje podľa definovaných prahov `distance_threshold`, čím sa postupne odstraňujú podlaha, steny a iné výrazné rovinné štruktúry.



Obrázok 3: Nasnímané mračno bodov po RANSAC algoritme



Obrázok 4: Stiahnuté mračno bodov po RANSAC algoritme

DBSCAN – hustotné klastrovanie

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) je algoritmus založený na hustote mračna bodov, ktorý nepotrebuje vopred poznať počet klastrov a dokáže identifikovať odľahlé body (šum).

Ide o robustný algoritmus schopný identifikovať klastre rôznych tvarov bez potreby predbežného určenia ich počtu. Hoci je odolný voči šumu, jeho účinnosť závisí od správneho nastavenia parametrov `eps` a `min_points`.



Obrázok 5: Nasnímané mračno bodov po DBSCAN algoritme



Obrázok 6: Stiahnuté mračno bodov po DBSCAN algoritme

Filtrovanie klastrov podľa veľkosti

Po klasifikácii sú body farebne označené podľa príslušnosti ku klastru. Keďže niektoré klastre môžu byť príliš malé (napríklad zvyšky šumu či artefakty), funkcia `filter_clusters_by_size()` zachová len klastre s počtom bodov nad stanovený limit (`min_points_per_cluster`). Ostatné sa odstránia.


K-Means – centroidové klastrovanie

K-Means je jednoduchý a účinný algoritmus, ktorý rozdeľuje mračno bodov do **k** klastrov podľa vzdialenosti k najbližšiemu centroidu (stredy klastra). Počet klastrov určuje používateľ.

Algoritmus začína náhodnou inicializáciou **k** centroidov. Každý bod sa následne priradí k najbližšiemu centroidu a centroidy sa prepočítajú ako priemery všetkých priradených bodov. Tento proces pokračuje, kým sa centroidy prestanú meniť alebo sa dosiahne maximálny počet iterácií.



Obrázok 7: Nasnímané mračno bodov po K-means algoritme



Obrázok 8: Stiahnuté mračno bodov po K-means algoritme

K-Means vyniká svojou rýchlosťou a škálovateľnosťou, čo z neho robí účinný nástroj na segmentáciu dát, najmä pri klastroch guľového tvaru s podobnou hustotou. Jeho nevýhodou je potreba vopred určiť počet klastrov a citlivosť na počiatočnú polohu centroidov. Nie je vhodný pre dáta s nerovnomernou hustotou ani pre klastre s nelineárnymi tvarmi.

Parametre algoritmov

Keďže pracujeme s dvoma rôznymi objektmi, pre jednotlivé funkcie potrebujeme zvoliť rôzne parametre:

	<i>output3611.pcd(snímaný)</i>	<i>Pl_Major_4M_downsampled.ply</i>
<i>Ransac distance threshold</i>	0.06,0.08	0.2
<i>Ransac number points</i>	4	3
<i>Dbscan epsilon</i>	0.035	0.5
<i>Dbscan minimum points</i>	15	25
<i>K-means clusters</i>	2	10
<i>K-means minimum points per cluster</i>	50	50

Porovnanie algoritmov DBSCAN a K-means

Na základe obrázkov 5-8 je možné zhodnotiť, že DBSCAN bol na túto úlohu vhodnejší, keďže mračná bodov boli neštrukturalizované a častokrát bez jednoznačného počtu objektov.

K-means potreboval presný počet klusterov a nebol schopný určiť objekt ako celok, keďže objekty neboli dobre štrukturované.